



UNIVERSIDADE ESTADUAL DE CAMPINAS  
Faculdade de Tecnologia

**Larissa Benevides Vieira**

**Avaliação do impacto da diminuição dos horizontes na  
predição intradiária de ações utilizando redes neurais  
LSTM**

Limeira  
2022

**Larissa Benevides Vieira**

**Avaliação do impacto da diminuição dos horizontes na predição  
intradiária de ações utilizando redes neurais LSTM**

Monografia apresentada à Faculdade de Tecnologia  
da Universidade Estadual de Campinas como parte  
dos requisitos para a obtenção do título de Bacharel  
em Sistemas de Informação.

**Orientador: Prof. Dr. Guilherme Palermo Coelho**  
**Coorientadora: Prof. Dra. Ana Estela Antunes da Silva**

Este exemplar corresponde à versão final da  
Monografia defendida por Larissa Benevides  
Vieira e orientada pelo Prof. Dr. Guilherme  
Palermo Coelho.

Limeira  
2022

Ficha catalográfica  
Universidade Estadual de Campinas  
Biblioteca da Faculdade de Tecnologia  
Luiz Felipe Galeffi - CRB 8/10385

V673a Vieira, Larissa Benevides, 1998-  
Avaliação do impacto da diminuição dos horizontes na predição intradiária de ações utilizando redes neurais LSTM / Larissa Benevides Vieira. – Limeira, SP : [s.n.], 2022.

Orientador: Guilherme Palermo Coelho.  
Coorientador: Ana Estela Antunes da Silva.  
Trabalho de Conclusão de Curso (graduação) – Universidade Estadual de Campinas, Faculdade de Tecnologia.

1. Redes neurais (Computação). 2. Mercado de ações - Previsão. I. Coelho, Guilherme Palermo, 1980-. II. Silva, Ana Estela Antunes da, 1965-. III. Universidade Estadual de Campinas. Faculdade de Tecnologia. IV. Título.

Informações adicionais, complementares

**Título em outro idioma:** Evaluation of the impact of shortening horizons on intraday stock prediction using LSTM neural networks

**Palavras-chave em inglês:**

Neural networks (Computer science)

Stock price forecasting

**Titulação:** Bacharel

**Banca examinadora:**

Guilherme Palermo Coelho [Orientador]

Ana Estela Antunes da Silva

João Roberto Bertini Júnior

Arthur Emanuel de Oliveira Carosia

**Data de entrega do trabalho definitivo:** 05-12-2022

# Agradecimentos

Primeiramente, agradeço ao Cursinho Comunitário Pimentas, pela ajuda para ingressar em uma Universidade Pública de grande prestígio, que me possibilitou obter o conhecimento que possuo atualmente.

Aos meus pais, que sempre me incentivaram ao estudo e a seguir a carreira que eu almejava.

Ao meu orientador e minha coorientadora que me auxiliaram durante todo o processo de escrita e revisão dessa monografia, além de terem sido, durante a graduação, professores didáticos e preocupados em compartilhar o conhecimento de forma clara e concisa.

Por fim, termino com essa frase que resume a minha vivência universitária: "Universidade Pública muda vidas, por isso lute por ela."

# Resumo

Prever variações de preço em bolsas de valores é um grande desafio devido ao fato de este ser um ambiente extremamente dinâmico e complexo. Além disso, a possibilidade de obter lucro durante as oscilações intradiárias, aquelas que ocorrem em um mesmo dia, torna a previsibilidade ainda mais desafiadora. Embora a Hipótese do Mercado Eficiente indique que não é possível, a partir de quaisquer informações previamente conhecidas, prever as variações futuras, diversos estudos baseados em Aprendizado de Máquina e, principalmente, Aprendizagem Profunda, estão buscando encarar tal desafio e tentando invalidar essa hipótese. Tais estudos foram capazes de alcançar resultados satisfatórios na previsão de preços de ações, utilizando-se de dados históricos financeiros. Por esse motivo, este trabalho realizou um levantamento de bases históricas intradiárias de 3 ações do setor bancário - Banco BTG Pactual (BPAC11), Banco Bradesco (BBDC4) e Itaú Unibanco (ITUB4) - coletadas da B3, tendo como finalidade realizar previsões de tendência de preços de séries temporais, utilizando a rede neural recorrente conhecida como *Long Short-Term Memory* (LSTM). O propósito foi verificar como se comporta a acurácia de predição conforme comprimimos o horizonte de previsão. A análise dos resultados obtidos, representados por gráficos *box-plots*, demonstraram que não houve um aumento ou diminuição dos valores de acurácia das ações BPAC11 e ITUB4, enquanto somente a ação BBDC4 obteve um aumento na mediana e uma diminuição na dispersão dos dados, conforme o horizonte de predição era reduzido.

**Palavras-chave:** LSTM, previsão de ações, previsão intradiária, horizonte de previsão, Redes Neurais Artificiais.

# Abstract

Predicting price variations on stock exchanges is a major challenge due to the fact that this is an extremely dynamic and complex environment. Furthermore, the possibility of making a profit during intraday swings, those that occur on the same day, makes predictability even more challenging. Although the Efficient Market hypothesis infers that it is not possible to predict any advance information as future variations, several studies based on Machine Learning and, particularly Deep Learning are seeking to face such a challenge and trying to disprove this hypothesis, as satisfactory results were achieved in forecasting stock prices using historical financial data. For this reason, this work carried out a survey based on intraday historical databases of three banking sector stocks - Banco BTG Pactual (BPAC11), Banco Bradesco (BBDC4) and Itaú Unibanco (ITUB4) - with the purpose of making time series price trend forecasts, using the recurrent neural network known as *Long Short-Term Memory* (LSTM). The purpose was to verify how the prediction accuracy behaves as we compress the forecast horizon. The analysis of the obtained results, represented by *box-plots* graphics, showed that there was no increase or decrease in the accuracy values of the stocks BPAC11 and ITUB4, while only the stock BBDC4 obtained an increase in the median and a decrease in the data dispersion, as the prediction horizon was reduced.

**Palavras-chave:** LSTM, stock forecasting, intraday forecasting, forecast horizon, Artificial Neural Networks.

# Lista de Figuras

2.1	Tendências da análise técnica. . . . .	16
2.2	Tendências da análise técnica de acordo com a duração. . . . .	17
2.3	Série temporal financeira representada por um gráfico <i>Candlestick</i> utilizando a ação do Banco BTG Pactual para o ano de 2021. . . . .	17
2.4	Relação entre uma rede neural biológica e artificial. . . . .	19
2.5	Estrutura de um neurônio artificial do tipo <i>Perceptron</i> . . . . .	20
2.6	Rede neural <i>feedforward</i> . . . . .	20
2.7	Rede neural recorrente. . . . .	21
2.8	Arquitetura de uma rede neural LSTM. . . . .	22
4.1	Retornos logarítmicos de dados de fechamento de 30 em 30 minutos com seus respectivos valores rotulados. . . . .	29
4.2	Retornos logarítmicos de dados de fechamento de 30 em 30 minutos. . . . .	29
4.3	Retornos logarítmicos de dados de fechamento de 30 em 30 minutos atrasados em 4 <i>lags</i> . . . . .	30
5.1	<i>Box-plot</i> do BTG Pactual com dados de acurácia separados em horizontes de 3 horas, 1 hora e 30 minutos. . . . .	35
5.2	<i>Box-plot</i> do Banco Bradesco com dados de acurácia separados em horizontes de 3 horas, 1 hora e 30 minutos. . . . .	36
5.3	<i>Box-plot</i> do Itaú Unibanco com dados de acurácia separados em horizontes de 3 horas, 1 hora e 30 minutos. . . . .	37

# Lista de Tabelas

4.1	Número total de amostras utilizadas durante as fases de treinamento e teste separadas pelas ações financeiras e seus respectivos horizontes. . . . .	30
5.1	Total de dados de preço de fechamento utilizados como entrada para a rede durante a fase de treinamento e teste da ação BBDC4. . . . .	36



# Sumário

<b>1</b>	<b>Introdução</b>	<b>10</b>
1.1	Motivação . . . . .	11
1.2	Objetivos . . . . .	12
1.3	Organização da monografia . . . . .	12
<b>2</b>	<b>Fundamentação teórica</b>	<b>14</b>
2.1	Introdução ao Mercado Financeiro . . . . .	14
2.1.1	Análise Técnica . . . . .	16
2.2	Séries temporais financeiras . . . . .	17
2.2.1	Retorno de séries temporais financeiras . . . . .	18
2.3	Redes Neurais Artificiais . . . . .	18
2.3.1	Neurônio Artificial . . . . .	19
2.3.2	Redes Neurais <i>feedforward</i> e Redes Neurais Recorrentes . . . . .	20
2.3.3	<i>Long Short-Term Memory</i> (LSTM) . . . . .	22
<b>3</b>	<b>Trabalhos Relacionados</b>	<b>23</b>
3.1	Predição de preços das ações . . . . .	23
3.2	Predição de tendências do preço das ações . . . . .	25
<b>4</b>	<b>Metodologia</b>	<b>27</b>
4.1	Coleta de dados . . . . .	27
4.2	Tratamento dos dados . . . . .	28
4.3	Classificação . . . . .	28
4.4	Modelo de Rede Neural . . . . .	29
4.4.1	Entrada e saída da rede . . . . .	29
4.4.2	Treinamento e teste dos dados . . . . .	30
4.4.3	Otimização de hiperparâmetros . . . . .	31
4.4.4	Estrutura da Rede . . . . .	31
<b>5</b>	<b>Resultados Experimentais</b>	<b>33</b>
5.1	Análise dos resultados . . . . .	34
5.1.1	Banco BTG Pactual . . . . .	34
5.1.2	Banco Bradesco . . . . .	35
5.1.3	Itaú Unibanco . . . . .	37
<b>6</b>	<b>Conclusão</b>	<b>38</b>
6.1	Trabalhos futuros . . . . .	39
	<b>Referências bibliográficas</b>	<b>41</b>

# Capítulo 1

## Introdução

O mercado de ações tem um papel importante na economia, pois é a partir dele que as empresas de capital aberto negociam frações de seu patrimônio, ou seja, as ações. Em geral, as operações de compra e venda do mercado de capital acontecem em bolsa de valores, e são nelas que o investidor pode querer vender suas ações por achar que o preço delas vai cair, ou optar por comprá-las, na crença de que seu valor vai aumentar.

Essas negociações de venda e compra podem ser realizadas em um período de um dia, definidas como operações intradiárias, ou mais de um dia, nomeadas como *swing trade*.

Por esse motivo, o processo de tomar melhores decisões acerca de vender ou comprar um ativo se torna cada vez mais complexo devido à liquidez e volatilidade do mercado de ações, visto que o preço de um ativo pode sofrer diversas alterações em um dia e uma decisão errada pode acarretar em perdas financeiras para o investidor. Isso se torna mais evidente quando há tentativas de previsão intradiárias, onde os investidores buscam especular rapidamente com o mercado no curtíssimo prazo, o que exige um melhor entendimento de quando comprar e vender uma ação (REIS, T., 2021).

Com o intuito de conseguir prever valores futuros e tomar decisões mais eficientes relacionadas ao mercado de ações, cada vez mais, pesquisadores têm utilizado métodos de previsão do mercado de ações, como a análise técnica, com o intuito de obter vantagens transacionais a partir da análise gráfica do histórico de preço das ações.

Além disso, com o avanço da tecnologia e do poder computacional, a área de Inteligência Computacional, especificamente utilizando-se de *Deep Learning* - Aprendizagem Profunda, tem sido amplamente empregada para prever tendências e preços em séries temporais finan-

ceiras. Essas previsões também tomam como base o uso de cotações históricas de preços para prever os valores de ações futuros (SEZER; GUDELEK; OZBAYOGLU, 2020).

Embora hipóteses como a do Mercado Eficiente de Fama (1970), que sustenta a ideia de que os retornos no mercado são independentes, logo, defendem que não é possível utilizar nenhuma informação conhecida para prever os preços futuros, estudos na área de previsão financeira, com utilização de Redes Neurais Artificiais, têm se mostrado promissores tanto na previsão de tendência de subida e descida das ações, quanto na previsão de valores de ações e de sua possibilidade de auferir lucros (HSU et al., 2016).

Em razão disso, o propósito deste trabalho é utilizar uma arquitetura de Rede Neural Artificial conhecida como *Long Short-Term Memory* (LSTM) para prever o comportamento de índices intradiários da bolsa de valores de São Paulo, denominada B3.

O foco principal é analisar como se comporta a acurácia dos preditores em diferentes horizontes de predição, conforme os dados históricos são comprimidos em intervalos curtos de 3 horas, 1 hora e 30 minutos.

## 1.1 Motivação

Devido à modernização tecnológica, a utilização da Inteligência Artificial tem se tornado uma aliada em diversas áreas da sociedade, desde a área da saúde, na indicação de diagnósticos de doenças, até o setor da economia financeira, que tem sido explorado utilizando algoritmos de *Machine Learning* para previsão de valores e tendências de preços do mercado de ações, como mostrado em Hu, Zhao e Khushi (2021) e Sezer, Gudelek e Ozbayoglu (2020).

Nesse sentido, a tecnologia para previsão do mercado financeiro vem como aliada para a tomada de melhores decisões, pois busca retirar a intervenção humana, dado que o mercado se torna cada vez mais complexo, volátil e de difícil administração. Nesse sentido, recorre-se a algoritmos para prever padrões, tornando o processo cada vez mais automático, a fim de facilitar o investimento no mercado financeiro.

Além disso, de acordo com Hsu et al. (2016), a partir de uma revisão de estudos relacionados à previsão de séries temporais financeiras, notou-se uma tendência maior de pesquisas focadas em horizontes de previsão de um dia ou mais, ou seja, faltam pesquisas relacionadas a tentativas de previsão intradiárias, que utilizam um horizonte de curto prazo, como minutos ou horas.

Por conta disso, essa investigação será focada em previsão de dados intradiários, para que se possa contribuir para mais pesquisas nessa área, visto que há investidores que realizam negociações em um mesmo dia.

Já em relação à utilização da rede neural LSTM, segundo o levantamento bibliográfico de Hu, Zhao e Khushi (2021), a maior parte dos trabalhos acerca de previsão de preços de ações usando *Deep Learning* foram realizados com este modelo de rede neural, que tem levado a resultados superiores em relação a outros tipos de modelos de Rede Neural utilizadas nesse contexto.

## 1.2 Objetivos

Este trabalho tem como principal objetivo utilizar conhecimentos de Aprendizado de Máquina para previsões de séries temporais financeiras. O propósito é verificar como se comporta a acurácia de predição conforme se diminui o horizonte preditivo.

Como objetivos específicos temos:

- Coletar e utilizar dados históricos de preços relacionados às ações: Banco BTG Pactual (BPAC11), Banco Bradesco (BBDC4) e Itaú Unibanco (ITUB4), listadas na bolsa de valores do Brasil, a B3.
- Propor um modelo de previsão a partir de dados de preço utilizando técnicas de aprendizado de máquina, mais especificamente, da rede neural recorrente designada LSTM.
- Realizar previsão a partir dos dados de fechamento de preço das ações intradiárias, operando com horizontes curtos de previsão, especificamente, 3 horas, 1 hora e 30 minutos.
- Analisar os resultados encontrados identificando como se comporta a acurácia conforme o horizonte de predição diminui.

## 1.3 Organização da monografia

Esta monografia está organizada da seguinte forma:

- No Capítulo 2 são apresentados conceitos teóricos necessários para o entendimento geral do trabalho. São introduzidos conteúdos acerca do mercado financeiro, previsão de séries temporais e redes neurais artificiais.

- No Capítulo 3 são abordados trabalhos relacionados a previsão de ações e tendências de séries financeiras, os quais servirão de base para aplicações das metodologias utilizadas.
- No Capítulo 4 consta a metodologia utilizada, sendo explicada de maneira minuciosa para que haja um bom entendimento da sua aplicação.
- No Capítulo 5 são analisados e descritos os resultados experimentais obtidos.
- No Capítulo 6 são expostas as conclusões finais, juntamente com temas relevantes a serem explorados em trabalhos futuros.

# Capítulo 2

## Fundamentação teórica

Este capítulo apresenta uma introdução sobre conceitos gerais para o entendimento desta monografia. São abordados conceitos introdutórios acerca do mercado financeiro, séries temporais financeiras e, por último, conceitos importantes de aprendizado de máquina, que serviram como base para a pesquisa realizada neste trabalho.

### 2.1 Introdução ao Mercado Financeiro

Segundo Celso Evandro dos Reis e Triches (2007), o mercado financeiro é constituído de um conjunto de vários mercados conectados em que são feitas negociações financeiras. Essas negociações são realizadas por meio de investidores que compram e vendem ativos, desde títulos emitidos por bancos, até títulos de empresas de capital aberto denominadas ações, negociados em Bolsa de valores, como a brasileira B3.

Os investidores realizam a compra de um ativo quando acreditam que o preço está em alta ou há uma expectativa da subida de preço no futuro, e vendem quando acreditam que o preço irá diminuir, de forma a obter lucro. A depender da estratégia, o investidor pode investir tanto buscando ganhos no longo prazo, quanto no curto prazo. Neste segundo caso, o investidor se concentra em investimentos intradiários.

Intradiário, em inglês *intraday* ou *day trading*, é um termo utilizado no mercado financeiro para tratar do período de um dia de negociação na Bolsa de Valores (RETORNO, 2019), sendo que o ativo foi adquirido e vendido ao longo da abertura e fechamento do mesmo pregão.

Portanto, por ser possível realizar negociações em um curto prazo, os investidores que buscam obter ganhos com esse tipo de operação devem se atentar a dois principais fatores: o

primeiro é como o mercado se movimenta e o segundo é analisar os gráficos de variações de preços.

As negociações intradiárias são separadas em três modalidades principais: *Day Trade*, *High Trade Frequency* e *Scalper trading* (ALMEIDA, 2022) (RETORNO, 2019).

A modalidade de operação *Day Trade* se baseia em uma estratégia de comprar e vender ativos no mesmo dia. Desse modo, investidores utilizam os gráficos intradiários para decidir qual o momento mais propício para comprar ou vender uma ação, lucrando sobre as flutuações de curtíssimo prazo.

A negociação de alta frequência ou *High Trade Frequency* em inglês é uma estratégia que explora o volume e frequência das negociações para obter ganhos sobre micro variações de preço ao longo de um *intraday*. São bastante estudadas na literatura, em previsões de ações intradiárias utilizando dados de alta frequência com métodos estatísticos e/ou de Aprendizado de Máquina, como visto em Tang et al. (2021) e Henrique, Sobreiro e Kimura (2018).

A *Scalper trading* é um tipo de operação realizada com o auxílio de softwares de *trade* e programas de análise gráfica. Nesse tipo de operação, a solidez de um ativo e o seu histórico não são importantes, sendo priorizada o volume e sua condição imediata, pois as negociações desse tipo duram poucos minutos.

Ademais, saber o momento certo de comprar e vender um ativo com o intuito de obter ganhos, principalmente em um curto prazo, é um desafio gigantesco, uma vez que os preços oscilam constantemente.

Devido a essa inconsistência na previsão dos valores, existe um debate sobre a possibilidade de prever as mudanças nas previsões de ações de forma assertiva. A Hipótese do Mercado Eficiente, proposta por Fama (1970), afirma que o preço atual de um ativo sempre reflete toda a informação previamente existente, ou seja, não é possível utilizar nenhuma informação conhecida para prever preços futuros.

Por outro lado, devido ao desenvolvimento da computação, diversos estudos começaram a questionar a hipótese de Fama (1970) e mostraram que, de fato, é possível prever os preços com algum grau de precisão, não sendo estes, portanto, aleatórios (ATSALAKIS; VALAVANIS, 2009) (LO; MACKINLAY, 2011).

Nesses estudos, foram evidenciados métodos de previsão do mercado de ações, que foram criados com o intuito de obter vantagens transacionais. Os principais métodos de previsão utilizados nessa monografia são discutidos a seguir.

### 2.1.1 Análise Técnica

A análise técnica ou comumente chamada de análise gráfica, é um método de investimento que avalia várias estatísticas de acordo com a atividade histórica do mercado e identifica padrões que podem ter implicações para as previsões futuras dos preços dos ativos (GEVA; ZAHAVI, 2014), ou seja, utiliza o preço histórico das ações para tentar identificar o seu preço futuro.

O objetivo dessa análise é rastrear o comportamento de um ativo através de seu histórico e mudanças de preços como indicadores valiosos para encontrar o momento certo de comprar e vender um ativo.

Esse tipo de análise é muito usada por investidores que atuam com renda variável, sobretudo com compra e venda de ações em períodos relativamente curtos (GONSALES, 2021). Por meio desse tipo de análise, os investidores podem identificar três tipos de tendências de preços do ativo: tendência de alta, tendência de baixa e tendência lateral, conforme mostrado na Figura 2.1.



Figura 2.1: Tendências da análise técnica.

Fonte: Investidor (2014).

A tendência de alta ocorre quando há uma maior demanda por um ativo específico e, consequentemente, seu preço sobe. No que tange a tendência de baixa, ela ocorre quando existe uma maior oferta por um ativo específico e, assim, seu preço cai. Por último, a tendência lateral ocorre quando o mercado está estável, devido a um equilíbrio entre a oferta e a demanda do ativo.

Além das três tendências de preços, há três categorias principais de tendências de acordo com sua duração, sendo essas definidas como tendência primária ou principal, secundária ou intermediária e terciária ou curto prazo, conforme mostrado na Figura 2.2:

A tendência primária é a tendência de mais longo prazo e pode durar vários anos. Já a tendência secundária é a tendência mediana, formada por movimentos que ocorrem ao longo





Figura 2.2: Tendências da análise técnica de acordo com a duração.  
Fonte: Investidor (2014).

da tendência primária. Por fim, a tendência terciária é a tendência que dura somente alguns dias, caracterizada pelos curtos movimentos que ocorrem em torno de uma tendência primária.

Conforme mostrado na Figura 2.2, a tendência primária é mostrada entre o ponto 1 e 4, a tendência secundária é identificada entre os pontos 2 e 3, e por último, a tendência terciária é identificada pelos pontos A e B.

## 2.2 Séries temporais financeiras

Uma série temporal é definida como uma sequência de valores, ordenados cronologicamente e observados em intervalos constantes ao longo do tempo (TORRES et al., 2021).

Segundo Morettin e Tolo (2006), estudar séries temporais é importante para a realização de previsões de valores futuros da série, principalmente em estudos de previsão de séries financeiras, compostas geralmente por cotações históricas de ativos da bolsa de valores. A Figura 2.3 ilustra um exemplo de série temporal financeira.




Figura 2.3: Série temporal financeira representada por um gráfico *Candlestick* utilizando a ação do Banco BTG Pactual para o ano de 2021.

Fonte: Próprio Autor

### 2.2.1 Retorno de séries temporais financeiras

Alguns estudos que envolvem séries temporárias financeiras não utilizam o preço de um ativo, mas sua série de retorno.

De acordo com Conti (2019), a utilização das séries de retorno apresentam propriedades estatísticas melhores para modelar comportamentos temporais financeiros. Além disso, por estarem livres de escala, o uso de retornos facilitam análises quando comparados com as séries de preços (MORETTIN, 2008).

Uma abordagem popularmente utilizada na literatura para calcular o retorno de um ativo é denominado de log-retorno.

A definição de log-retorno é dada pela Equação 2.1, em que  $\log(p_t)$  corresponde ao log do preço do ativo no dia  $t$  que é subtraído pelo log do preço do ativo do dia anterior, representado por  $\log(p_{t-1})$ .

$$r_t = \log(p_t) - \log(p_{t-1}) \quad (2.1)$$

Esta monografia adota o cálculo de log-retorno para estimar o retorno a cada instante das séries escolhidas.

## 2.3 Redes Neurais Artificiais

As Redes Neurais Artificiais, conhecidas como RNAs, podem ser definidas, de um modo geral, como modelos matemáticos inspirados na estrutura neural do cérebro humano, conhecida como rede neural biológica. As RNAs têm diferentes tipos de modelos de neurônios e arquiteturas, e cada uma delas é escolhida em função do problema a ser solucionado.

Um dos primeiros modelos de neurônio artificial foi proposto por McCulloch e Pitts (1943). Eles assumiram que o neurônio executa uma função lógica, com o intuito de abstrair a complexidade da atividade neural em sistemas neurais reais, assim como as complicadas características encontradas no corpo de neurônios biológicos, formando a base para a maioria dos modelos subsequentes, como os de arquitetura mais simples como o *Perceptron* e as redes mais complexas como o *Multilayer Perceptron*.

Dessa forma, as RNAs possuem unidades simples de processamento, denominados neurônios (ou nós), que são interconectados gerando uma rede de neurônios, as redes neurais. As informações (sinais) são transmitidos entre neurônios através de conexões ou sinapses. A efi-

ciência de uma sinapse, representada por pesos ou pesos sinápticos, corresponde à informação armazenada pelo neurônio e, portanto, pela rede neural (DE CASTRO L.N; FERRARI, 2016). E os mecanismos responsáveis por transportar informações entre os neurônios são representadas, nas RNAs, por funções de ativação (NELSON, 2017).

Para ilustrar melhor a abstração entre uma rede neural biológica e uma rede neural artificial, a Figura 2.4 apresenta um paralelo entre a ilustração de um neurônio biológico e um artificial.




Figura 2.4: Relação entre uma rede neural biológica e artificial.

Fonte: Souza (2019).

### 2.3.1 Neurônio Artificial

O neurônio artificial é uma unidade de processamento de informação com papel fundamental para a operação da rede neural, e por esse motivo é primordial entender como funcionam as partes principais que o compõem. Segundo Haykin (2008), a sinapse é caracterizada pelos pesos associados, a junção somadora e a função de ativação. A Figura 2.5 apresenta a estrutura tradicional de um neurônio artificial conhecido como *perceptron*.

Cada variável de entrada  $x_1, x_2, \dots, x_m$  corresponde a uma característica da amostra de dados sendo apresentada à rede. Os pesos  $w_{j1}, w_{j2}, \dots, w_{jm}$  associados a cada entrada determinam a força do sinal de disparo da conexão, ou seja, a representatividade de cada atributo para o neurônio. Os valores de entrada são multiplicados por seus pesos correspondentes e agregados sob um combinador linear. Além disso, nessa etapa há também a inclusão de um limiar de viés denominado  $b_j$ , capaz de aumentar ou diminuir o valor de saída a ser utilizado na função de ativação (HAYKIN, 2001). Por fim, a função de ativação limita o valor de saída  $y$  do neurônio, e introduz não linearidade no modelo (DE CASTRO L.N; FERRARI, 2016).




Figura 2.5: Estrutura de um neurônio artificial do tipo *Perceptron*.  
Fonte: Fiorin et al. (2011).

### 2.3.2 Redes Neurais *feedforward* e Redes Neurais Recorrentes

Para que seja possível entender sobre redes neurais recorrentes (RNN), é necessário compreender também o que são redes neurais *feedforward*.

Tanto as redes neurais *feedforward* ou *perceptrons* multicamadas (MLPs) (GOODFELLOW; BENGIO; COURVILLE, 2016b), quanto as redes neurais recorrentes recebem o nome da forma como canalizam as informações, através de uma série de operações matemáticas realizadas nos nós da rede.

No que tange as redes *feedforward*, as informações se movem em apenas uma direção, passando primeiro pelas camadas de entrada (*input layer*), depois se movendo para as camadas intermediárias (*hidden layers*), e por último pela camada de saída (*output layer*) conforme mostrado na Figura 2.6. Ou seja, nesse exemplo de rede, não há conexões de realimentação nas quais as saídas do modelo sejam realimentadas, por esse motivo, as informações transmitidas nunca passam pelo mesmo nó duas vezes.




Figura 2.6: Rede neural *feedforward*.  
Fonte: (FACURE, 2017).

As redes *feedforward* são de extrema importância para os praticantes de aprendizado de máquina pois, formam a base de muitas aplicações comerciais importantes. Porém, essa rede não é eficiente para resolver problemas que envolvem dados que apresentam relações temporais, porque elas não possuem nenhuma memória do *input* que receberam previamente, apenas o atual, não existindo assim noção de ordem no tempo.

Diferentemente das redes *feedforward*, as redes neurais recorrentes aceitam como entrada não apenas o exemplo de entrada atual, mas também o que perceberam anteriormente no tempo. Factualmente, as redes neurais recorrentes fazem uso de observações sequenciais e aprendem com os estágios anteriores para prever tendências futuras.

De maneira prática, a rede neural recorrente recebe entrada de duas fontes: uma do presente, e outra de um ponto passado. A informação das duas fontes são utilizadas para decidir como reagir a uma nova entrada de dados, e isso é feito através de um circuito de *feedback*, onde a saída de cada instante é uma entrada para o instante seguinte, conforme ilustrado na Figura 2.7.




Figura 2.7: Rede neural recorrente.  
Fonte: (BARBOSA et al., 2021).

Essa particularidade das RNNs permite que essas redes sejam adequadas para utilização em previsões de séries temporais, pois elas são capazes de realizar a mesma tarefa para cada elemento da sequência, com a característica de utilizar informações capturadas anteriormente para prever dados sequenciais futuros não vistos.

Contudo, o principal desafio ao se utilizar uma RNN genérica é que essas redes lembram apenas algumas etapas anteriores na sequência e, portanto, não são adequadas para lembrar sequências de dados mais longas. Para resolver esse problema, é possível utilizar um tipo de rede neural recorrente bastante conhecida, intitulada *Long Short-Term Memory* (LSTM).

### 2.3.3 Long Short-Term Memory (LSTM)

*Long Short-Term Memory* (LSTM) (HOCHREITER; SCHMIDHUBER, 1997) é um tipo de RNN em que a rede lembra valores de longo prazo. São consideradas poderosas em problemas de previsão de séries temporais porque são capazes de armazenar informações passadas. Essa informação é extremamente importante nessa monografia porque o preço anterior de uma ação é utilizado para prever seu preço futuro.

A principal diferença entre a célula LSTM e a célula RNN simples é que a LSTM adiciona um regulador para julgar se a informação é útil ou não. A estrutura deste regulador é chamada de porta ou *gate* em inglês (ZHANG, X.; TAN, 2018).

A unidade LSTM usual consiste em uma célula (a parte da memória da unidade LSTM) e três *gates*, designados respectivamente de porta de entrada (*input gate*), porta de esquecimento (*forget gate*) e porta de saída (*output gate*).

A Figura 2.8 ilustra como ocorre o fluxo de informações pela célula e portas de uma unidade de uma LSTM.

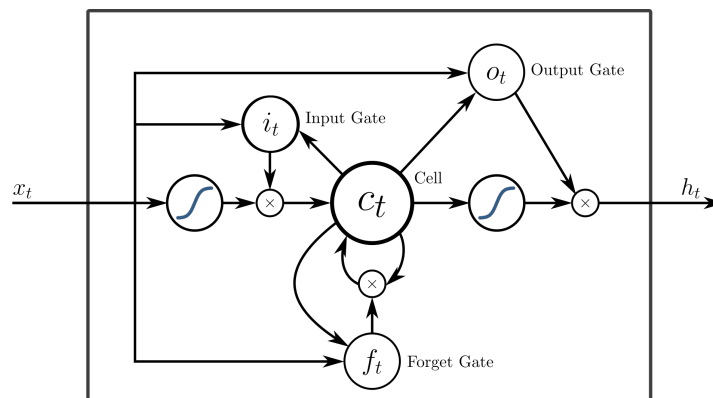


Figura 2.8: Arquitetura de uma rede neural LSTM.

Fonte: (COHEN, 2022).

Conforme mostrado na Figura 2.8, o  $c_t$  é a célula na qual os processos principais são conduzidos. Basicamente, um dado entra na rede pela porta de entrada (*Input Gate*) ou  $i_t$  que controla se uma informação útil é adicionada ao estado da célula (ZHANG, X.; TAN, 2018). Após isso, na porta de esquecimento (*Forget Gate*) ou  $f_t$  é feito o controle daquelas informações que não são mais necessárias na célula (WANG, C., 2021), que são esquecidas nessa porta. Por último, é responsabilidade da porta de saída (*Output Gate*) ou  $o_t$  extrair informações úteis do estado da célula atual para serem apresentadas como uma saída para o neurônio da LSTM.

## Capítulo 3

# Trabalhos Relacionados

Existem diversos estudos utilizando históricos de preços para realizar previsões no mercado financeiro. Essas previsões, em sua maioria, recorrem a algoritmos de *Machine Learning* e *Deep Learning* para realizar tipos diferentes de previsão. Em especial, há dois principais tipos de previsões que podem ser citadas por servirem de base para esse projeto.

- Previsão de preços das ações.
- Previsão de tendência de preços das ações.

Outro ponto importante é a diferenciação entre horizontes de previsão. Estes mostram o quanto longe no futuro um modelo consegue prever e podem variar entre minutos, horas, dias, semanas ou meses.

Por esse motivo, este capítulo está separado em tipos de previsão do mercado de ações e seus respectivos horizontes de previsão, quando mencionados pelos autores.

Por fim, este levantamento se focou em reunir trabalhos relacionados à utilização de LSTM para previsão de séries temporais, com enfoque em horizontes curtos, como segundos, minutos, e horas. Porém outras pesquisas também relacionadas à previsão do mercado financeiro são apresentadas, dada sua relevância para a presente monografia.

### 3.1 Predição de preços das ações

A previsão de preços de qualquer ação é uma área amplamente estudada. Dependendo do horizonte de tempo de previsão, diferentes parâmetros de entrada são escolhidos, variando de

negociações de alta frequência - *High Frequency Trading* (HFT), movimentos de preços intra-diários a preços de fechamento de ações diários, semanais ou mesmo mensais.

Além disso, dados de análise técnica, fundamentalista, *feeds* de mídia social e sentimento presente em notícias relacionadas estão entre os diferentes parâmetros usados para os modelos de previsão.

No contexto brasileiro, no trabalho de Vasco (2020) foram utilizados três modelos de redes neurais recorrentes simples, o *Vanilla Recurrent Neural Network* (VRNN), o *Long Short-Term Memory* (LSTM) e o *Gated Recurrent Unit* (GRU) para a previsão de valores de diferentes ações da bolsa de valores brasileira. O horizonte de predição utilizado foi um dia à frente. Além disso, para obter uma boa comparação, foram calculados o erro absoluto médio e o erro quadrático médio, sendo que os modelos GRU e LSTM obtiveram melhores resultados.

Já em Dezsi e Nistor (2016), usando LSTM, foram analisados dados do mercado de ações da Romênia na tentativa de prever o preço em log-retorno das ações no dia seguinte. Foram comparados os resultados usando as ferramentas clássicas de modelagem estatística, e os autores chegaram à conclusão que a rede LSTM obteve resultados promissores.

Enquanto isso, outro estudo implementou alguns modelos de redes neurais profundas para comparação de desempenho usando apenas dados de preços brutos. No estudo de Samarawickrama e Fernando (2017) foi realizada uma comparação entre a rede *feedforward*, Rede Neural Recorrente (RNN), Rede Neural Recorrente Estrutural (SRNN), LSTM e GRU. Os preços de fechamento, alta e baixa dos últimos dois dias foram selecionados como variáveis de entrada e foram comparados os preços previstos com os preços reais. Embora citado pelo autor que em seus estudos, a LSTM sempre produzia os melhores resultados, neste estudo em específico, os modelos de MLP se saíram melhores, devido ao pequeno número de variáveis de entrada fornecidas para a rede.

Por último, diferentemente dos modelos anteriores, A. Araújo, Oliveira e Meira (2015) estudaram a previsão do mercado de ações de alta frequência, propondo um modelo híbrido denominado de aumento do neurônio linear decrescente (IDLN). Embora a utilização desse modelo não seja o foco deste trabalho, a sua citação é importante, pois nele são utilizados preços de ações da Bolsa de Valores de São Paulo, e são focados em um horizonte de previsão de segundos, algo característico de previsões utilizando dados de alta frequência.



## 3.2 Predição de tendências do preço das ações

Apesar da previsão de tendências e a previsão de preços compartilharem as mesmas características de entrada, alguns pesquisadores preferem prever a direção do preço de um ativo em vez de seu preço real. Isso altera a natureza do problema de estimação para classificação, e as métricas de desempenho correspondentes também mudam. No entanto, é importante notar que essas duas abordagens ainda são fundamentalmente as mesmas; a diferença está na interpretação da saída. Na literatura, existem diferentes métodos de previsão de tendências.

No trabalho de Nelson (2017), foi utilizado LSTM para estimativa do movimento do preço das ações. Os dados utilizados foram de preço de ativos negociados na BM&F Bovespa, o qual é o enfoque deste trabalho. Foram coletados dados consolidados de 15 minutos em 15 minutos e os testes foram realizados em aproximadamente um mês de negociação. Os resultados obtidos foram satisfatórios, obtendo uma acurácia média de até 55,9% ao prever se o preço de uma determinada ação iria subir ou não no futuro imediato. O modelo também foi avaliado sob aspectos financeiros mostrando resultados promissores em termos de retorno financeiro.

De maneira semelhante, em Mesquita e Machado Pereira (2019), com o intuito de criar estratégias automatizadas de operação no mercado, utilizou-se a rede neural LSTM como modelo de previsão de tendências nos preços das séries financeiras, comparando-a com um preditor aleatório. Em uma das metodologias, foram utilizados os dados históricos intradiários de 38 ações da bolsa de valores, com periodicidade de 15 minutos, referentes ao último quadrimestre de 2016 para a previsão de tendência de alta e baixa das ações. Os resultados obtidos demonstraram ser promissores, uma vez que os modelos LSTM utilizados obtiveram valores de acurácia 15% maiores em relação ao preditor aleatório.

Em Tsantekidis et al. (2017) utilizou-se dados de série temporal de alta frequência, e um método LSTM para prever a direção para a qual o preço iria mudar. Neste experimento os primeiros sete dias são usados para treinar a rede, enquanto os próximos três dias são usados como dados de teste. Utilizou-se para este modelo três horizontes de predição de curto prazo, e foram realizadas comparações com outras técnicas, como SVMs e MLPs. O resultado demonstrou que a LSTM teve um desempenho significativamente melhor.

Com o intuito de também realizar comparações, Song (2018) utilizou preços de 20 ações dos EUA, recursos de análise técnica e quatro modelos de *Machine Learning* diferentes, como LSTM, GRU, SVM e *eXtreme Gradient Boosting* (XGBoost) para prever a tendência dos preços de

ações nos próximos dias. Os resultados revelaram que as redes neurais recorrentes utilizadas tiveram o melhor desempenho em comparação com SVM e XGBoost.

Esta monografia utiliza como técnica a previsão de tendência de alta e baixa nos preços das ações.

# Capítulo 4

## Metodologia

Neste estudo foram utilizados dados históricos do mercado financeiro para três ações da B3. Os dados foram coletados e pré-processados, e o modelo proposto foi treinado e testado, a fim de analisar os resultados obtidos.

### 4.1 Coleta de dados

Foram coletados dados de preço de fechamento de três ações negociadas na B3 do ano de 2021. O ano de 2021 foi escolhido, pois era o período de um ano completo mais recente possível.

As três ações escolhidas são relacionadas ao setor bancário, sendo elas do Banco BTG Pactual (BPAC11), Banco Bradesco (BBDC4) e Itaú Unibanco (ITUB4), o qual possuem grande volume de negociações na bolsa de valores, logo apresentam maior liquidez.

Os dados coletados foram retirados do site *Tradingview*<sup>1</sup>, o qual possibilitou a extração de dados intradiários, com possibilidade de selecionar horizontes distintos.

Os horizontes utilizados nessa monografia são de 3 horas, 1 hora e 30 minutos, ou seja, a base de dados possui dados de preços de fechamento consolidados a cada 3 horas, 1 hora e 30 minutos, desde a abertura de negociações diária, até o fechamento do pregão.

---

<sup>1</sup><https://br.tradingview.com/>

## 4.2 Tratamento dos dados

Com os dados coletados de preço de fechamento foi realizado uma verificação com a finalidade de remover valores nulos, incorretos ou inconsistentes. Em seguida, os dados foram normalizados com o intuito de facilitar a convergência no treinamento e generalização na previsão.

O método de normalização utilizado foi a diferença entre o *log* do preço atual em relação ao anterior, ou seja, o denominado log-retorno citado anteriormente no Capítulo 2.2.1 dessa monografia.

Após a aplicação do log-retorno, somente para os dados de entrada da rede, com o intuito de converter cada valor para seu valor padronizado e fazer com que os dados de entrada fiquem com valores próximos de 0, foi utilizado a normalização gaussiana ou popularmente conhecida como *z-score*.

O *z-score* possibilita colocar os dados na mesma escala ao subtraí-los pela média da série e, em seguida, dividi-lo pelo desvio padrão da mesma conforme mostrado na Equação 4.1:

$$z = \frac{x - \mu}{\sigma} \quad (4.1)$$

Nessa monografia, seguindo a metodologia utilizada em Hilpisch (2020), foram calculados a média e o desvio padrão somente usando os dados de treinamento. Após o cálculo, o valor da média e do desvio padrão dos dados de treinamento foram aplicados tanto na equação *z-score* dos dados de treinamento, quanto na equação que continha os dados de teste.

## 4.3 Classificação

Para cada entrada normalizada inserida no modelo de rede neural, uma classe binária é atribuída. Os valores de log-retorno financeiro positivo são classificados com valor 1, indicando uma tendência de alta nos preços. Já os valores de log-retorno negativo e valores 0, são classificados com valor 0, indicando uma tendência de queda nos preços. A Figura 4.1 ilustra essa classificação.

	log-retorno	direção
time		
2021-01-04T10:30:00-03:00	-0.001105	0
2021-01-04T11:00:00-03:00	-0.000737	0
2021-01-04T11:30:00-03:00	-0.013742	0
2021-01-04T12:00:00-03:00	-0.002996	0
2021-01-04T12:30:00-03:00	-0.007530	0
...	...	...
2021-12-30T15:30:00-03:00	0.002594	1
2021-12-30T16:00:00-03:00	-0.002594	0
2021-12-30T16:30:00-03:00	0.000000	0
2021-12-30T17:00:00-03:00	-0.001040	0
2021-12-30T17:30:00-03:00	-0.001041	0

Figura 4.1: Retornos logarítmicos de dados de fechamento de 30 em 30 minutos com seus respectivos valores rotulados.

Fonte: Próprio Autor

## 4.4 Modelo de Rede Neural

### 4.4.1 Entrada e saída da rede

O modelo de rede neural LSTM criado recebe como entrada os valores de log-retorno atrasados em 4 *lags*, seguindo a metodologia utilizada por Mesquita e Machado Pereira (2019). Isso significa que para cada linha de informação no tempo  $t$ , do valor de log-retorno, são adicionadas mais três variáveis, com os valores de log-retorno de  $t-1$ ,  $t-2$ , e  $t-3$ .

Para exemplificar, a Figura 4.2 contém uma amostra de dados de preços normalizados utilizando log-retorno, com dados consolidados de 30 em 30 minutos.

	log-retorno
time	
2021-01-04T10:30:00-03:00	-0.001105
2021-01-04T11:00:00-03:00	-0.000737
2021-01-04T11:30:00-03:00	-0.013742
2021-01-04T12:00:00-03:00	-0.002996
2021-01-04T12:30:00-03:00	-0.007530

Figura 4.2: Retornos logarítmicos de dados de fechamento de 30 em 30 minutos.

Fonte: Próprio Autor

Com a aplicação dos preços atrasados em 4 *lags*, a rede neural receberá os três valores de preço passados  $[-0.013742 \ -0.000737 \ -0.001105]$  mais o preço atual  $[-0.002996]$  para prever a classe de alta ou baixa do preço futuro  $[-0.007530]$ , que nesse caso seria 0, porque o valor de log-retorno é negativo, conforme mostrado na Figura 4.3.

	log-retorno	direção	lag_1	lag_2	lag_3	lag_4
time						
2021-01-04T12:30:00-03:00	-0.007530	0	-0.002996	-0.013742	-0.000737	-0.001105

Figura 4.3: Retornos logarítmicos de dados de fechamento de 30 em 30 minutos atrasados em 4 *lags*.

Fonte: Próprio Autor

A classe binária prevista, com valor 0, seria a saída da rede, que nessa circunstância informa que houve uma tendência de baixa no preço, porém em situações que o valor de log-retorno é positivo, a saída seria 1, informando que houve uma tendência de alta no preço.

#### 4.4.2 Treinamento e teste dos dados

Os dados são divididos em conjunto de treinamento e teste, mantendo a ordem temporal das observações. Os dados de teste são usados para avaliar a precisão do modelo de previsão proposto e não são usados no treinamento.

Nessa monografia, para as três ações do mercado financeiro utilizadas, os dados foram separados em 80% para treinamento e 20% para teste.

A Tabela 4.1 ilustra o número total de amostras, que são utilizadas nas fases de treinamento e teste, separadas pelas respectivas ações financeiras. Nesse contexto, uma amostra contém 4 entradas que são associadas a 1 saída.

	3h	1h	30min
BBDC4	735	1967	3933
BPAC11	735	1965	3927
ITUB4	735	1967	3933

Tabela 4.1: Número total de amostras utilizadas durante as fases de treinamento e teste separadas pelas ações financeiras e seus respectivos horizontes.

Fonte: Próprio Autor

### 4.4.3 Otimização de hiperparâmetros

Os hiperparâmetros são configurações de um modelo de *Machine Learning* que podem ser ajustados para otimizar o desempenho e a qualidade do algoritmo de aprendizado (BERGSTRA; BENGIO, 2012). Com eles é possível tornar o modelo mais assertivo para a previsão de dados. Por esse motivo, são atributos que precisam ser escolhidos com cautela.

Um dos métodos tradicionais de otimização de hiperparâmetros é a pesquisa em grade (LIASHCHYNSKYI; LIASHCHYNSKYI, 2019). A pesquisa em grade ou *Grid Search*, pode auxiliar no ajuste de hiperparâmetros em um modelo de *Deep Learning*, especificando valores diferentes para os hiperparâmetros e escolhendo um subconjunto que resulte em um modelo que alcance o melhor desempenho em um determinado conjunto de dados.

Nessa monografia, empregando a metodologia aplicada por Brownlee (2022), foi utilizada a biblioteca *scikit-learn*<sup>2</sup> para os seguintes valores dos hiperparâmetros: (i) 10, 20, 40, 60, 80, 100 tamanho do lote; (ii) 10, 50, 100, 500 número de épocas; (iii) 0.0001, 0.001, 0.01, 0.1, 0.2, 0.3 taxa de aprendizagem do otimizador *Adam* e (iv) 1, 5, 10, 15, 20, 25, 30, 35, 40, 45, 50, 55, 60, 65, 70, 75, 80, 85, 90, 95, 100 neurônios na camada oculta.

Como as redes neurais profundas tendem a apresentar diferentes resultados mesmo quando treinadas e avaliadas com o mesmo conjunto de dados, a pesquisa em grade é repetida 30 vezes, utilizando os dados de treinamento, e é escolhido o valor que alcançou o melhor resultado o maior número de vezes.

### 4.4.4 Estrutura da Rede

O modelo de rede neural proposto foi instanciado utilizando a implementação de redes LSTM presente na biblioteca *TensorFlow*<sup>3</sup> sendo utilizada sob a interface da biblioteca *Keras*<sup>4</sup>. O código na linguagem de programação *Python* está disponível no *GitHub*<sup>5</sup>.

O modelo possui uma camada LSTM que espera que os dados recebidos na entrada sejam tridimensionais. Isso significa que a camada de entrada espera uma matriz 3D de dados ao ajustar o modelo e ao fazer previsões (BROWNLEE, 2017), com as seguintes dimensões:

- Amostras (*Samples*): o número de amostras é o tamanho do *dataset* utilizado em cada ação selecionada, conforme ilustrado na Tabela 4.1 do Capítulo 4.4.2.

---

<sup>2</sup><https://scikit-learn.org/stable/>

<sup>3</sup><https://www.tensorflow.org/>

<sup>4</sup><https://keras.io/>

<sup>5</sup>[https://github.com/BeneInfosec/Inteligencia\\_Artificial](https://github.com/BeneInfosec/Inteligencia_Artificial)

- Espaços de tempo (*Time Steps*): o número de espaços de tempo é o valor de *lags* utilizado. Nessa monografia foram utilizados 4 *lags*.
- Recursos (*Features*): o número de recurso é 1, pois é utilizado somente o valor de fechamento da ação para a realização da predição.

Após realizar a configuração dos dados para um formato tridimensional, a camada de entrada pode ser instanciada.

A primeira camada da LSTM possui cinco neurônios com função de ativação *relu* e embora a camada receba como forma de entrada uma matriz 3D, ela é instanciada com valor 4 o qual representa o número de *lags*, e valor 1 caracterizando o número de recursos.

A função de ativação *relu* é utilizada, pois é fácil de computar e acelera a convergência do treinamento de acordo com Lei Zhang, Shuai Wang e Liu (2018).

A última camada instanciada é a camada densa, que possui 1 neurônio e uma função de ativação *sigmoid*, recomendada para problemas de classificação binária. A função retorna um valor no intervalo entre 0 e 1, representando o pertencimento da saída a uma determinada classe.

Para a configuração do modelo para treinamento é utilizado o otimizador *Adam* com a taxa de aprendizado definida a partir do *Grid Search* como 0.001. O otimizador *Adam* foi escolhido por conter diversos benefícios. Segundo Kingma e Ba (2014), seus criadores, o *Adam* possui uma implementação simples, e o algoritmo, por ser adaptativo, se sai bem em problemas não estacionários, ou seja, ruidosos. Além disso, é um dos algoritmos de otimização mais popularmente utilizado (GOODFELLOW; BENGIO; COURVILLE, 2016a). Adicionalmente, uma função de perda denominada entropia cruzada binária, indicada para problemas de classificação binária (0 ou 1), é implementada. Por último, como métrica, é utilizado a acurácia. A acurácia é o número de instâncias classificadas corretamente dividido pelo número total de instâncias.

Após realizada a configuração do modelo, ele é treinado utilizando os dados de treinamento. Esses dados são organizados em entradas, que são atrasadas em 4 *lags*, e em saídas que são rotuladas em 0s ou 1s. Além disso, a partir do *Grid Search* foi definido como 10 o número de épocas e 40 o tamanho do lote.

Ademais, o modelo é avaliado em relação a acurácia 30 vezes utilizando os dados de teste, os quais não foram utilizados durante o treinamento do modelo.

Por último, alguns gráficos *box-plots* são gerados com o intuito de avaliar como se comporta a acurácia conforme o horizonte de predição é comprimido.



## Capítulo 5

# Resultados Experimentais

Este capítulo apresenta os experimentos realizados e resultados obtidos utilizando a metodologia descrita no Capítulo 4 dessa monografia.

Para a criação do modelo, foram utilizadas três ações do mercado financeiro, BPAC11, BBDC4 e ITUB4, do ano de 2021, contendo três horizontes de predição, sendo de 3 horas, 1 hora e 30 minutos.

O modelo foi treinado recebendo como entrada para a rede o valor de log-retorno dos dados de preço de fechamento atrasados em 4 *lags*, e prevendo como saída, as classes 0 e 1, rotuladas a partir dos valores de log-retorno.

Para avaliar o quão bem o modelo generaliza para dados não vistos, utilizaram-se dados de testes, não vistos pelo modelo de treinamento, para analisar como se comporta a acurácia do modelo conforme o horizonte de previsão é delimitado, ou seja, conforme diminui de forma gradativa, começando com 3 horas, depois com 1 hora e por fim, com 30 minutos.

A avaliação foi executada 30 vezes para cada um dos três horizontes de predição escolhidos, ou seja, a cada execução foi gerado um valor de acurácia, totalizando 30 valores de acurácia para cada horizonte de predição. Para cada ação, foram comparados os três horizontes de predição, isso significa que, para a ação BPAC11, foram comparados os horizontes de 3 horas, 1 hora e 30 minutos, e para a ação BBDC4 e ITUB4 também foram comparados os mesmos horizontes.

Os 30 valores de acurácia para cada horizonte de predição de cada ação, foram plotados em gráficos *box-plots* para auxiliar na análise dos resultados.

## 5.1 Análise dos resultados

Para analisar os resultados de acurácia obtidos, foram criados três gráficos *box-plots*, referentes a cada ação financeira, separados pelos três horizontes de predição escolhidos, conforme Figura 5.1, Figura 5.2 e Figura 5.3.

Os gráficos *box-plots* foram utilizados pois apresentam parâmetros que podem indicar diversas características importantes sobre o conjunto de dados a serem analisados. Essas características incluem informações como posição, dispersão, simetria e valores discrepantes.

A posição está relacionada ao valor numérico da mediana dos dados, a qual é representada pela linha central do retângulo no gráfico.

A dispersão é demonstrada pelo comprimento das caixas que são os intervalos interquartis, ou pela amplitude que é a diferença entre o valor máximo e o valor mínimo, que representa quanto os dados estão dispersos entre cada amostra. Quanto maior a caixa, mais dispersos os dados, e quanto menor, menos disperso os dados.

A simetria é representada pela posição da mediana em relação ao comprimento da caixa. Os dados serão simétricos se a linha da mediana se situar no centro do retângulo, e serão assimétricos se a linha mediana se posicionar mais acima ou mais abaixo dentro do retângulo.

E os valores discrepantes ou *outliers* indicam possíveis valores numericamente discrepantes ou distantes do resto do conjunto de dados, sendo demonstrados nos gráficos como pontos dispersos.

### 5.1.1 Banco BTG Pactual

Analisando a ação do Banco BTG Pactual, ilustrada na Figura 5.1, pode se observar que, em relação à posição dos dados, conforme o horizonte de predição é comprimido, nota-se que não há uma linearidade de aumento ou diminuição na acurácia mediana de classificação. A mediana em um horizonte de 3 horas começa com uma acurácia de 57,1%, depois com 1 hora o valor decai, com um resultado de 53,3% e com 30 minutos volta a subir para 53,5%, porém não chega próximo do primeiro valor.

Outra característica que não possui linearidade é a dispersão dos dados conforme o horizonte é comprimido. Com o horizonte de 3 horas, o comprimento da caixa varia de 56,4% a 57,8%, obtendo uma diferença aproximada de 1,4%, porém ao diminuir para 1 hora, o valor varia entre 51,9% a 54,1%, sendo uma diferença de 2,2%, uma variação maior do que a anterior,

e com 30 minutos, o valor varia entre 53% a 53,9%, ou seja, uma diferença menor do que a anterior, com o valor de 0,9%.

Em relação à simetria dos dados, é observado que, conforme o horizonte de predição é comprimido, os dados de acurácia ficam com uma distribuição assimétrica. Com um horizonte de 3 horas, os dados são simétricos, ou seja, possuem a mesma simetria, porém com a diminuição para 1 hora, e posteriormente para 30 minutos, os dados possuem uma distribuição assimétrica.




Figura 5.1: *Box-plot* do BTG Pactual com dados de acurácia separados em horizontes de 3 horas, 1 hora e 30 minutos.

Fonte: Próprio Autor

### 5.1.2 Banco Bradesco

Ao analisar os dados do *box-plot* da ação do Banco Bradesco, ilustrada na Figura 5.2, conforme o horizonte de predição é comprimido, observa-se que há um aumento significativo no valor mediano da acurácia.

A mediana em um horizonte de 3 horas começa com uma acurácia de 52,3%, depois com 1 hora o valor aumenta, com um resultado de 55% e com 30 minutos sobe com uma variação pequena, com um valor de acurácia de 55,1%.

No que se refere a dispersão de dados, ela diminui conforme a diminuição do tempo. É notório observar que o horizonte de 3 horas possui o maior comprimento da caixa se comparado

aos horizontes de 1 hora e 30 minutos, ou seja, às dispersão dos valores de acurácia são maiores, demonstrando valores entre 54,4% a 51%, uma diferença de 3,4%. Ao diminuir o horizonte para 1 hora, há uma menor dispersão dos dados, variando de 55,3% a 54,8%, diferença de 0,5%. Com 30 minutos, a dispersão é menor que a anterior, variando de 55,4% a 55,1%, diferença de 0,3%.




Figura 5.2: *Box-plot* do Banco Bradesco com dados de acurácia separados em horizontes de 3 horas, 1 hora e 30 minutos.

Fonte: Próprio Autor

Constatou-se que além do horizonte de 30 minutos possuir uma menor dispersão nos dados, também possui os maiores valores de acurácia, se comparado com os outros horizontes de predição. Provavelmente, isso se deve à quantidade de dados disponíveis para a rede. Notou-se que conforme o horizonte é comprimido, o número de dados treinados e testados aumenta, conforme ilustrado na Tabela 5.1. Por esse motivo, suponha-se que um aumento significativo de dados utilizados poderia melhorar a acurácia dos horizontes de 3 horas e 1 hora.

	3h	1h	30min
Treinamento	588	1573	3146
Teste	147	394	787

Tabela 5.1: Total de dados de preço de fechamento utilizados como entrada para a rede durante a fase de treinamento e teste da ação BBDC4.

Fonte: Próprio Autor

### 5.1.3 Itaú Unibanco

Ao examinar o *box-plot* da ação do Itaú Unibanco ilustrada na Figura 5.3, é possível observar não linearidade na posição dos dados, ou seja na mediana dos números de acurácia conforme o horizonte de predição é comprimido, pois com um horizonte de 3 horas, o número mediano da acurácia, é de 58,8%, uma média alta, se comparada com os horizontes menores de 1 hora e 30 minutos, que contém respectivamente os valores 53,2% e 54,6%.

No que tange os valores de dispersão dos dados, há uma menor dispersão conforme o horizonte é comprido, porém não de maneira decrescente. É verificado, a partir da análise da Figura 5.3, que o horizonte de 3 horas possui o maior comprimento de caixa, com um valor de acurácia que varia de 60,5% a 55,7%, uma diferença de 4,8% se compararmos entre os horizontes de 1 hora e 30 minutos, que respectivamente possuem os seguintes valores numéricos, entre 53,5% a 53,2%, ou seja, uma diferença de 0,3% e entre 55% e 54,3%, uma diferença de 0,7%. Porém ao realizarmos essa mesma comparação somente entre os horizontes de 1 hora e 30 minutos, observa-se que o horizonte de 1 hora possui uma menor dispersão dos dados, se comparado com o horizonte de 30 minutos.




Figura 5.3: *Box-plot* do Itaú Unibanco com dados de acurácia separados em horizontes de 3 horas, 1 hora e 30 minutos.

Fonte: Próprio Autor

## Capítulo 6

### Conclusão

Esta monografia utilizou dados históricos de preços de três ações do setor bancário do ano de 2021 para identificar como se comporta a acurácia conforme o horizonte de predição é delimitado em 3 horas, 1 hora e 30 minutos.

Para atingir esse objetivo, o primeiro passo, foi realizar um levantamento bibliográfico de trabalhos similares na literatura envolvendo previsões tanto de valores de preços de ações financeiras, quanto tendência de alta e baixa dessas ações.

A partir do levantamento foi possível concluir que o modelo de rede neural recorrente LSTM seria o modelo ideal a ser utilizado, pois obteve melhores valores de acurácia se comparado com outros modelos de rede neural. Além disso, vários desses trabalhos descritos no levantamento bibliográfico serviram como base para a escolha e aplicação da metodologia utilizada nessa monografia.

Na metodologia os dados coletados foram pré-processados e posteriormente utilizados no modelo LSTM proposto. Em seguida, utilizou-se um método bastante conhecido para encontrar os melhores parâmetros para o treinamento do modelo: o *Grid Search*.

O modelo foi treinado utilizando os dados de treinamento e recebendo como entrada para a rede o valor de log-retorno dos dados de preço de fechamento atrasados em 4 *lags*, e prevendo, como saída, as classes 0 e 1, rotuladas a partir dos valores de log-retorno.

Após a realização do treinamento, o modelo foi avaliado utilizando os dados de teste, e os resultados obtidos foram representados e analisados em gráficos *box-plots*.

Por meio da análise dos resultados, foi possível constatar a não linearidade dos valores de acurácia da mediana e dispersão dos dados das ações BPAC11 e ITUB4, em função da compres-

são do horizonte de predição, e foi observado somente uma linearidade nos valores de acurácia da ação BBDC4.

Na ação BPAC11, a mediana com um horizonte de 3 horas começa com um valor de acurácia alto, depois com 1 hora o valor decai e com 30 minutos o valor volta a subir. Na ação ITUB4 observou-se um padrão semelhante em relação a mediana, que começou com um valor de acurácia alto com um horizonte de 3 horas, depois com 1 hora o valor diminui, e com 30 minutos o valor aumenta.

Em relação à dispersão dos dados na ação BPAC11, a diferença dos valores de acurácia dos intervalos interquartis começa baixo com horizonte de 3 horas, depois o valor aumenta com 1 hora, e o valor decai com 30 minutos. No que se refere a ação ITUB4, a diferença dos valores de acurácia dos intervalos interquartis possui uma diferença alta com 3 horas, porém com 1 hora o valor diminui, e com 30 minutos ele volta a aumentar.

No que tange, a ação BBDC4 obteve um aumento no valor da mediana e uma diminuição da dispersão dos dados, conforme o horizonte de predição diminuía.

Por fim, conclui-se que não houve possibilidade de ter certeza se intervalos menores fornecem uma predição com maior acurácia, visto que somente uma ação demonstrou um aumento de acurácia na mediana e uma menor dispersão dos dados, dando maior confiabilidade na sua assertividade. Porém com as outras duas ações do setor bancário, não foi possível obter a mesma conclusão.

## 6.1 Trabalhos futuros

A pesquisa realizada nesta monografia pode ser estendida em alguns aspectos. O primeiro aspecto é a utilização da rede neural LSTM com outros períodos de tempo além do ano de 2021, para avaliar se os resultados se mantêm os mesmos.

O segundo ponto seria testar a rede com um conjunto de treinamento maior, além de variar os métodos de treino e teste, aplicando técnicas de validação cruzada e janelas deslizantes. No sentido de aprendizado de máquina, pode-se testar utilizando outras arquiteturas de rede neural, como MLP ou GRU.

Outros tipos de métricas poderiam ser utilizadas no lugar da acurácia, como por exemplo, o erro de predição.

Além disso, outros horizontes de predição poderiam ser escolhidos focando-se em ações intradiárias, como por exemplo, ações consolidadas de 15 em 15 minutos.

Pode-se estender o trabalho buscando também modelar o problema de classificação em mais de duas classes, por exemplo classe de Altas, Baixas e Movimentos Laterais, ou em um problema de regressão ao invés de classificação.

No que tange a metodologia, pode-se realizar um estudo buscando indicadores técnicos e outros atributos (valores de volume, máximo e mínimo do dia, entre outros) para se obter melhores resultados de predição.

Por último, seria interessante comparar os resultados obtidos com outros experimentos, como por exemplo, outras implementações de algoritmos de aprendizado de máquina.



## Referências bibliográficas

A. ARAÚJO, R. de; OLIVEIRA, A. L.; MEIRA, S. A hybrid model for high-frequency stock market forecasting. **Expert Systems with Applications**, v. 42, n. 8, p. 4081–4096, 2015. ISSN 0957-4174. DOI: <https://doi.org/10.1016/j.eswa.2015.01.004>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0957417415000093>>.

ALMEIDA, G. (Ed.). **Intraday: saiba mais sobre este tipo de operação**. 2022. Disponível em: <<https://www.certifiquei.com.br/intraday/>>. Acesso em: 30 out. 2022.

ATSALAKIS, G. S.; VALAVANIS, K. P. Surveying stock market forecasting techniques – Part II: Soft computing methods. **Expert Systems with Applications**, v. 36, 3, Part 2, p. 5932–5941, 2009. ISSN 0957-4174. DOI: <https://doi.org/10.1016/j.eswa.2008.07.006>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0957417408004417>>.

BARBOSA, G. et al. Segurança em Redes 5G: Oportunidades e Desafios em Detecção de Anomalias e Predição de Tráfego Baseadas em Aprendizado de Máquina. In: [s.l.: s.n.], out. 2021. p. 145–189. ISBN 9786587003658. DOI: 10.5753/sbc.7165.8.4.

BERGSTRA, J.; BENGIO, Y. Random search for hyper-parameter optimization. **Journal of machine learning research**, v. 13, n. 2, 2012.

BROWNLEE, J. (Ed.). **How to Grid Search Hyperparameters for Deep Learning Models in Python with Keras**. 2022. Disponível em: <<https://machinelearningmastery.com/grid-search-hyperparameters-deep-learning-models-python-keras/>>. Acesso em: 4 nov. 2022.

BROWNLEE, J. (Ed.). **How to Reshape Input Data for Long Short-Term Memory Networks in Keras**. 2017. Disponível em: <<https://machinelearningmastery.com/reshape-input-data-long-short-term-memory-networks-keras/>>. Acesso em: 4 nov. 2022.

COHEN, G. Algorithmic Trading and Financial Forecasting Using Advanced Artificial Intelligence Methodologies. **Mathematics**, v. 10, p. 3302, set. 2022. DOI: 10.3390/math10183302.

CONTI, J. P. J. Redes neurais recorrentes e expoente de lyapunov aplicados a séries temporais financeiras. **Dissertação apresentada ao Programa de Pós-graduação em Engenharia Elétrica e Informática Industrial da Universidade Tecnológica Federal do Paraná**, 2019.

DE CASTRO L.N; FERRARI, D. **Introdução À Mineração De Dados: CONCEITOS BÁSICOS, ALGORITMOS E APLICAÇÕES**. [S.l.]: SARAIVA EDITORA, 2016. ISBN 9788547200985. Disponível em: <<https://books.google.com.br/books?id=7HxSvgaACAAJ>>.

DEZSI, E.; NISTOR, I. A. CAN DEEP MACHINE LEARNING OUTSMART THE MARKET? A COMPARISON BETWEEN ECONOMETRIC MODELLING AND LONG- SHORT TERM MEMORY. **Romanian Economic Business Review**, v. 11, n. 4.1, p. 54–73, 2016. Disponível em: <<https://EconPapers.repec.org/RePEc:rau:journl:v:11:y:2016:i:4.1:p:54-73>>.

FACURE, M. (Ed.). **Redes Neurais Feedforward Densas**. 2017. Disponível em: <<https://matheusfacure.github.io/2017/05/15/deep-ff-ann/>>. Acesso em: 13 nov. 2022.

FAMA, E. F. Efficient Capital Markets: A Review of Theory and Empirical Work. **Journal of Finance**, v. 25, n. 2, p. 383–417, mai. 1970. Disponível em: <<https://ideas.repec.org/a/bla/jfinan/v25y1970i2p383-417.html>>.

FIORIN, D.; MARTINS, F.; SCHUCH, N.; PEREIRA, E. Forecast of solar energy resource by using neural network methods. **Revista Brasileira de Ensino de Física**, v. 33, p. 01–20, mar. 2011.

GEVA, T.; ZAHAVI, J. Empirical evaluation of an automated intraday stock recommendation system incorporating both market data and textual news. **Decision Support Systems**, v. 57, p. 212–223, 2014. ISSN 0167-9236. DOI: <https://doi.org/10.1016/j.dss.2013.09.013>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0167923613002418>>.

GONSALES, T. (Ed.). **O que é Análise Técnica de Ações: Como Operar na Bolsa usando Análise Gráfica**. 2021. Disponível em: <<https://exame.com/invest/guia/analise-tecnica/>>. Acesso em: 30 out. 2022.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.l.]: MIT Press, 2016. (Adaptive Computation and Machine Learning series). ISBN 9780262035613. Disponível em: <<https://books.google.com.br/books?id=Np9SDQAAQBAJ>>.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.l.]: MIT Press, 2016. <http://www.deeplearningbook.org>.

HAYKIN, S. S. **Neural networks and learning machines**. Third. Upper Saddle River, NJ: Pearson Education, 2008.

HAYKIN, S. S. **Redes Neurais: Princípios e Prática**. [S.l.]: Bookman, 2001.

HENRIQUE, B. M.; SOBREIRO, V. A.; KIMURA, H. Stock price prediction using support vector regression on daily and up to the minute prices. **The Journal of Finance and Data Science**, v. 4, n. 3, p. 183–201, 2018. ISSN 2405-9188. DOI: <https://doi.org/10.1016/j.jfds.2018.04.003>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2405918818300060>>.

HILPISCH, Y. **Python for Algorithmic Trading: From Idea to Cloud Deployment**. [S.l.]: O'Reilly Media, Incorporated, 2020. (Python/Finance). ISBN 9781492053354. Disponível em: <<https://books.google.com.br/books?id=q4SXzQEACAAJ>>.

HOCHREITER, S.; SCHMIDHUBER, J. Long Short-term Memory. **Neural computation**, v. 9, p. 1735–80, dez. 1997. DOI: 10.1162/neco.1997.9.8.1735.

HSU, M.-W. et al. Bridging the divide in financial market forecasting: machine learners vs. financial economists. **Expert Systems with Applications**, v. 61, p. 215–234, 2016. ISSN 0957-4174. DOI: <https://doi.org/10.1016/j.eswa.2016.05.033>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0957417416302585>>.

HU, Z.; ZHAO, Y.; KHUSHI, M. A Survey of Forex and Stock Price Prediction Using Deep Learning. **Applied System Innovation**, v. 4, p. 9, fev. 2021. DOI: 10.3390/asi4010009.

INVESTIDOR, B. d. (Ed.). **Tendências na Análise Técnica**. 2014. Disponível em: <<https://www.bussoladoinvestidor.com.br/tendencias-na-analise-tecnica/>>. Acesso em: 30 out. 2022.

KINGMA, D. P.; BA, J. **Adam: A Method for Stochastic Optimization**. [S.l.]: arXiv, 2014. DOI: 10.48550/ARXIV.1412.6980. Disponível em: <<https://arxiv.org/abs/1412.6980>>.

LIASHCHYNSKYI, P.; LIASHCHYNSKYI, P. **Grid Search, Random Search, Genetic Algorithm: A Big Comparison for NAS**. [S.l.]: arXiv, 2019. DOI: 10.48550/ARXIV.1912.06059. Disponível em: <<https://arxiv.org/abs/1912.06059>>.

LO, A.; MACKINLAY, A. **A Non-Random Walk Down Wall Street**. [S.l.]: Princeton University Press, 2011. ISBN 9781400829095. Disponível em: <<https://books.google.com.br/books?id=AHNv1Pf3pQMC>>.

MCCULLOCH, W.; PITTS, W. A Logical Calculus of Ideas Immanent in Nervous Activity. **Bulletin of Mathematical Biophysics**, v. 5, p. 127–147, 1943.

MESQUITA, C. M.; MACHADO PEREIRA, A. C. Ciência de dados e aprendizado de máquina para predição em séries temporais financeiras. **Universidade Federal de Minas Gerais. Programa de Pós-Graduação em Ciência da Computação**, 2019.

MORETTIN, P. A.; TOLOI, C. M. C. **Análise de Séries Temporais**. Second. [S.l.]: São Paulo: Egard Blucher, 2006. ISBN 9788521203896. Disponível em: <[https://issuu.com/editorablucher/docs/issuu\\_analise\\_temporais\\_isbn9788521203896](https://issuu.com/editorablucher/docs/issuu_analise_temporais_isbn9788521203896)>.

MORETTIN, P. A. **Econometria financeira: um curso em séries temporais financeiras**. [S.l.]: Edgard Blücher, 2008.

NELSON, D. M. Q. Uso de redes neurais recorrentes para previsão de séries temporais financeiras. **Dissertação em Ciência da Computação do Instituto de Ciências Exatas da Universidade Federal de Minas Gerais - UFMG**, 2017.

REIS, C. E. d.; TRICHES, D. Seleção e composição de uma carteira de ações com base na técnica grafista. **Perspectiva Econômica**, p. 1–26, 2007.

REIS, T. (Ed.). **Entenda o que é intraday e quais operações são realizadas em apenas um dia**. 2021. Disponível em: <<https://www.suno.com.br/artigos/intraday/>>. Acesso em: 30 ago. 2018.

RETORNO, E. M. (Ed.). **Intraday**. 2019. Disponível em: <<https://maisretorno.com/portal/termos/i/intraday>>. Acesso em: 30 out. 2022.

SAMARAWICKRAMA, J.; FERNANDO, T. A Recurrent Neural Network Approach in Predicting Daily Stock Prices: An Application to the Sri Lankan Stock Market. In: DOI: 10.1109/ICIINFS.2017.8300345.

SEZER, O. B.; GUDELEK, M. U.; OZBAYOGLU, A. M. Financial time series forecasting with deep learning : A systematic literature review: 2005–2019. **Applied Soft Computing**, v. 90, p. 106181, 2020. ISSN 1568-4946. DOI: <https://doi.org/10.1016/j.asoc.2020.106181>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1568494620301216>>.

SONG, Y. Stock Trend Prediction: Based on Machine Learning Methods. UCLA. **ProQuest ID: Song<sub>u</sub>cla<sub>0</sub>031N<sub>1</sub>6607.MerrittID : ark : /13030/m5zs7sqk**, 2018.

SOUZA, A. (Ed.). **O QUE É UMA REDE NEURAL ARTIFICIAL? (CÓDIGO PYTHON)**. 2019. Disponível em: <<https://blogdozouza.wordpress.com/2019/12/09/como-codificar-uma-rede-neural-com-backpropagation-em-python-do-zero/>>. Acesso em: 20 jun. 2021.

TANG, Y.; XIAO, X.; WAHAB, M.; MA, F. The role of oil futures intraday information on predicting US stock market volatility. **Journal of Management Science and Engineering**, v. 6, n. 1, p. 64–74, 2021. ISSN 2096-2320. DOI: <https://doi.org/10.1016/j.jmse.2020.10.004>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2096232020300494>>.

TORRES, J. F. et al. Deep Learning for Time Series Forecasting: A Survey. **Big Data**, v. 9, n. 1, p. 3–21, 2021. PMID: 33275484. DOI: 10.1089/big.2020.0159. Disponível em: <<https://doi.org/10.1089/big.2020.0159>>.

TSANTEKIDIS, A. et al. Using deep learning to detect price change indications in financial markets. In: 2017 25th European Signal Processing Conference (EUSIPCO). [S.l.: s.n.], ago. 2017. p. 2511–2515. DOI: 10.23919/EUSIPCO.2017.8081663.

VASCO, L. P. Um estudo de redes neurais recorrentes no contexto de previsões no mercado financeiro. **Trabalho de conclusão do curso de graduação em engenharia de computação da Universidade Federal de São Carlos -UFSCAR**, 2020.

WANG, C. Using Latest Machine Learning Techniques to Conduct Stock Prediction. **California State Polytechnic University, Pomona**, 2021.

ZHANG, L.; WANG, S.; LIU, B. **Deep Learning for Sentiment Analysis : A Survey**. [S.l.]: arXiv, 2018. DOI: 10.48550/ARXIV.1801.07883. Disponível em: <<https://arxiv.org/abs/1801.07883>>.

ZHANG, X.; TAN, Y. Deep Stock Ranker: A LSTM Neural Network Model for Stock Selection. In: [s.l.: s.n.], jun. 2018. p. 614–623. ISBN 978-3-319-93802-8. DOI: 10.1007/978-3-319-93803-5\_58.